

IMPORT LIBRARY

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
import warnings
warnings.filterwarnings('ignore')
sns.set(style='whitegrid')
```

```
from google.colab import drive
drive.mount('/content/drive')
```

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True)

DATA UNDERSTANDING

Memuat Dataset

```
file = '/content/drive/MyDrive/Consumer_Shopping_Trends_2026 (6).csv'

df = pd.read_csv(file)
df
```

DESKRIPSI DATA

Informasi Dasar

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 11789 entries, 0 to 11788
Data columns (total 25 columns):
 #   Column                                Non-Null Count  Dtype
---  -
 0   age                                   11789 non-null  int64
 1   monthly_income                       11789 non-null  int64
 2   daily_internet_hours                 11789 non-null  float64
 3   smartphone_usage_years               11789 non-null  int64
 4   social_media_hours                   11789 non-null  float64
 5   online_payment_trust_score           11789 non-null  int64
 6   tech_savvy_score                     11789 non-null  int64
 7   monthly_online_orders                11789 non-null  int64
 8   monthly_store_visits                 11789 non-null  int64
 9   avg_online_spend                     11789 non-null  int64
10  avg_store_spend                      11789 non-null  int64
```

```

11 discount_sensitivity      11789 non-null int64
12 return_frequency         11789 non-null int64
13 avg_delivery_days        11789 non-null int64
14 delivery_fee_sensitivity  11789 non-null int64
15 free_return_importance    11789 non-null int64
16 product_availability_online 11789 non-null int64
17 impulse_buying_score      11789 non-null int64
18 need_touch_feel_score     11789 non-null int64
19 brand_loyalty_score       11789 non-null int64
20 environmental_awareness   11789 non-null int64
21 time_pressure_level       11789 non-null int64
22 gender                    11789 non-null object
23 city_tier                 11789 non-null object
24 shopping_preference       11789 non-null object
dtypes: float64(2), int64(20), object(3)
memory usage: 2.2+ MB

```

```
df.shape
```

```
(11789, 25)
```

Dataset yang digunakan dalam analisis ini terdiri dari:

- 11.789 baris (records)
- 25 kolom (features).

Setiap baris merepresentasikan satu individu konsumen, sedangkan setiap kolom merepresentasikan atribut atau karakteristik yang berkaitan dengan perilaku dan preferensi belanja konsumen.

▼ Informasi Lanjutan

Berikut merupakan informasi lanjutan yang disajikan untuk memberikan pemahaman lebih rinci mengenai struktur dan deskripsi setiap kolom pada dataset Consumer Shopping Trends Analysis. Informasi ini mencakup jumlah data, tipe data, serta penjelasan masing-masing atribut untuk mendukung proses eksplorasi dan analisis data.

1. age, jumlah baris: 11789, tipe data: int64, deskripsi: usia pelanggan yang digunakan untuk menganalisis perilaku belanja berdasarkan kelompok umur.
2. monthly_income, jumlah baris: 11789, tipe data: int64, deskripsi: pendapatan bulanan pelanggan yang mencerminkan daya beli konsumen.
3. daily_internet_hours, jumlah baris: 11789, tipe data: float64, deskripsi: rata-rata jumlah jam penggunaan internet per hari.
4. smartphone_usage_years, jumlah baris: 11789, tipe data: int64, deskripsi: lama penggunaan smartphone dalam tahun.
5. social_media_hours, jumlah baris: 11789, tipe data: float64, deskripsi: rata-rata waktu penggunaan media sosial per hari.
6. online_payment_trust_score, jumlah baris: 11789, tipe data: int64, deskripsi: tingkat kepercayaan terhadap sistem pembayaran online.
7. tech_savvy_score, jumlah baris: 11789, tipe data: int64, deskripsi: tingkat pemahaman dan kemampuan penggunaan teknologi.
8. monthly_online_orders, jumlah baris: 11789, tipe data: int64, deskripsi: jumlah transaksi online per bulan.
9. monthly_store_visits, jumlah baris: 11789, tipe data: int64, deskripsi: frekuensi kunjungan ke toko fisik per bulan.
10. avg_online_spend, jumlah baris: 11789, tipe data: int64, deskripsi: rata-rata pengeluaran belanja online.
11. avg_store_spend, jumlah baris: 11789, tipe data: int64, deskripsi: rata-rata pengeluaran di toko fisik.
12. discount_sensitivity, jumlah baris: 11789, tipe data: int64, deskripsi: tingkat sensitivitas terhadap diskon.
13. return_frequency, jumlah baris: 11789, tipe data: int64, deskripsi: frekuensi pengembalian barang.
14. avg_delivery_days, jumlah baris: 11789, tipe data: int64, deskripsi: rata-rata waktu pengiriman barang.
15. delivery_fee_sensitivity, jumlah baris: 11789, tipe data: int64, deskripsi: sensitivitas terhadap biaya pengiriman.
16. free_return_importance, jumlah baris: 11789, tipe data: int64, deskripsi: tingkat kepentingan layanan retur gratis.
17. product_availability_online, jumlah baris: 11789, tipe data: int64, deskripsi: persepsi terhadap ketersediaan produk di platform online.
18. impulse_buying_score, jumlah baris: 11789, tipe data: int64, deskripsi: kecenderungan melakukan pembelian impulsif.
19. need_touch_feel_score, jumlah baris: 11789, tipe data: int64, deskripsi: kebutuhan untuk melihat atau mencoba produk secara langsung sebelum membeli.
20. brand_loyalty_score, jumlah baris: 11789, tipe data: int64, deskripsi: tingkat loyalitas terhadap merek tertentu.
21. environmental_awareness, jumlah baris: 11789, tipe data: int64, deskripsi: tingkat kepedulian terhadap isu lingkungan dalam keputusan pembelian.

22. time_pressure_level, jumlah baris: 11789, tipe data: int64, deskripsi: tingkat tekanan waktu saat berbelanja.
23. gender, jumlah baris: 11789, tipe data: object, deskripsi: jenis kelamin pelanggan.
24. city_tier, jumlah baris: 11789, tipe data: object, deskripsi: kategori tingkat kota tempat tinggal pelanggan.
25. shopping_preference, jumlah baris: 11789, tipe data: object, deskripsi: preferensi metode belanja (Online, Store, atau Hybrid).

Statistik Deskriptif Dataset

```
df.describe(include='all')
```

	age	monthly_income	daily_internet_hours	smartphone_usage_years	social_media_hours	online_payment_trust
count	11789.000000	11789.000000	11789.000000	11789.000000	11789.000000	11789.000000
unique	NaN	NaN	NaN	NaN	NaN	NaN
top	NaN	NaN	NaN	NaN	NaN	NaN
freq	NaN	NaN	NaN	NaN	NaN	NaN
mean	48.729409	131704.282382	6.011367	7.597930	2.514471	5.000000
std	17.899445	68120.726684	1.976811	4.011628	1.263047	2.000000
min	18.000000	15005.000000	1.000000	1.000000	0.000000	1.000000
25%	33.000000	72450.000000	4.600000	4.000000	1.600000	3.000000
50%	49.000000	131916.000000	6.000000	8.000000	2.500000	5.000000
75%	64.000000	190505.000000	7.400000	11.000000	3.400000	8.000000
max	79.000000	249989.000000	12.000000	14.000000	6.000000	10.000000

11 rows × 7 columns

Statistik Deskriptif Dataset

1. Count (Kelengkapan Data)

Total jumlah baris data adalah **11.789**.

Berdasarkan hasil eksplorasi, seluruh kolom memiliki jumlah data yang sama yaitu **11.789** (non-null).

Perhitungan missing values:

- Semua kolom memiliki data tersedia = **11.789**
- Data hilang = **11.789 - 11.789 = 0**

Kesimpulan: Tidak terdapat missing values pada dataset. Seluruh kolom memiliki data lengkap sebanyak **11.789 baris**, sehingga dataset siap digunakan untuk analisis tanpa perlu penanganan data hilang.

2. Mean vs Median (Distribusi Data)

age

- Mean = **48.73**
- Median = **49**

Selisih = **48.73 - 49 = -0.27**

Distribusi relatif **simetris**.

monthly_income

- Mean = **131704.28**
- Median = **131916**

Selisih = **131704.28 - 131916 = -211.72**

Distribusi **cukup seimbang**.

daily_internet_hours

- Mean = **6.01**
- Median = **6.00**

Selisih = **0.01**

Distribusi **sangat normal**.

monthly_online_orders

- Mean = **24.68**
- Median = **25**

Selisih = **-0.32**

Distribusi relatif **simetris**.

monthly_store_visits

- Mean = **9.48**
- Median = **9**

Selisih = **0.48**

Sedikit **right-skewed**.

avg_online_spend

- Mean = **74554.93**
- Median = **74859**

Selisih = **-304.07**

Distribusi **stabil dan seimbang**.

social_media_hours

- Mean = **2.51**
- Median = **2.50**

Selisih = **0.01**

Distribusi **normal**.

3. Min dan Max (Validasi Logika)

age

- Min = **18**
- Max = **79**

Rentang = **61**

Masih dalam batas logis usia konsumen.

monthly_income

- Min = **15005**
- Max = **249989**

Rentang = **234984**

Variasi pendapatan cukup besar, tetapi masih realistis.

daily_internet_hours

- Min = **1**
- Max = **12**

Rentang = **11**

Masuk akal untuk aktivitas harian.

monthly_online_orders

- Min = **0**
- Max = **49**

Rentang = **49**

Menunjukkan variasi intensitas belanja online.

monthly_store_visits

- Min = **0**
- Max = **19**

Rentang = **19**

Masih dalam batas logis kunjungan toko.

avg_online_spend

- Min = **523**
- Max = **149996**

Rentang = **149473**

Variasi tinggi, berpotensi terdapat nilai ekstrem.

4. Standar Deviasi (Variabilitas Data)**age**

- Mean = **48.73**
- Std = **17.90**

Perbandingan = **0.37**

Variasi usia cukup beragam.

monthly_income

- Mean = **131704.28**
- Std = **68120.73**

Perbandingan = **0.52**

Variasi pendapatan **tinggi**.

daily_internet_hours

- Mean = **6.01**
- Std = **1.98**

Perbandingan = **0.33**

Variasi penggunaan internet **moderat**.

monthly_online_orders

- Mean = **24.68**
- Std = **14.43**

Perbandingan = **0.58**

Variasi aktivitas belanja online **tinggi**.

monthly_store_visits

- Mean = **9.48**
- Std = **5.73**

Perbandingan = **0.60**

Variasi kunjungan toko cukup besar.

social_media_hours

- Mean = **2.51**
- Std = **1.26**

Perbandingan = **0.50**

Variasi penggunaan media sosial **cukup tinggi**.

Kesimpulan


Berdasarkan analisis statistik deskriptif dataset Consumer Shopping Trends:

- Dataset memiliki **11.789 baris** dengan **tidak terdapat missing values** pada seluruh kolom.
- Sebagian besar variabel memiliki distribusi yang **relatif normal dan seimbang**, dengan sedikit indikasi skew pada beberapa variabel seperti kunjungan toko.
- Variasi terbesar terlihat pada variabel **pendapatan dan aktivitas belanja**, yang menunjukkan heterogenitas perilaku konsumen.
- Secara keseluruhan, data berada dalam rentang yang **logis dan valid**, meskipun terdapat potensi nilai ekstrem pada variabel pengeluaran dan pendapatan.

✓ EKSPLORASI DATA (EDA)

✓ Comparison

```
plt.figure(figsize=(8,5))
sns.countplot(data=df, x='shopping_preference')
plt.title('Distribusi Preferensi Belanja Pelanggan')
plt.xlabel('Shopping Preference')
plt.ylabel('Jumlah Pelanggan')
plt.show()
```




Visualisasi di atas menunjukkan bahwa mayoritas pelanggan sangat dominan memilih berbelanja secara langsung di toko Store dibandingkan metode lainnya. Jumlah pelanggan pada kategori Store terlihat jauh lebih tinggi, berada di kisaran lebih dari 10.000 pelanggan, sedangkan kategori Online hanya sekitar 1.000-an pelanggan dan Hybrid menjadi yang paling sedikit. Hal ini mengindikasikan bahwa perilaku konsumen dalam dataset masih sangat berfokus pada pengalaman belanja offline.

Selain itu, perbedaan jumlah yang sangat mencolok antar kategori menunjukkan adanya ketimpangan distribusi preferensi belanja. Preferensi Store yang mendominasi dapat mengindikasikan bahwa pelanggan lebih nyaman melihat produk secara langsung, melakukan pembayaran di tempat, atau adanya keterbatasan adopsi kanal digital pada data ini. Sementara itu, rendahnya kategori Hybrid menunjukkan bahwa kombinasi belanja online dan offline belum menjadi kebiasaan utama pelanggan.

```
purchase_freq = {
    'Online Orders': df['monthly_online_orders'].mean(),
    'Store Visits': df['monthly_store_visits'].mean()
}

plt.figure(figsize=(8,5))
sns.barplot(x=list(purchase_freq.keys()), y=list(purchase_freq.values()))
plt.title('Rata-rata Frekuensi Belanja Online vs Offline')
plt.xlabel('Jenis Aktivitas Belanja')
plt.ylabel('Rata-rata Frekuensi per Bulan')
plt.show()
```



Visualisasi di atas menunjukkan bahwa rata-rata jumlah pesanan online per bulan jauh lebih tinggi dibandingkan kunjungan ke toko fisik. Nilai Online Orders berada di kisaran sekitar 24 sampai 25 transaksi per bulan, sedangkan Store Visits hanya sekitar 9 sampai 10 kunjungan per bulan. Hal ini mengindikasikan bahwa pelanggan dalam dataset cenderung lebih sering melakukan transaksi melalui online dibandingkan datang langsung ke toko.


Perbedaan yang cukup signifikan ini menunjukkan adanya pergeseran perilaku konsumen ke arah digital shopping, di mana kemudahan akses, fleksibilitas waktu, dan kenyamanan berbelanja dari rumah kemungkinan menjadi faktor utama. Meskipun pada visualisasi sebelumnya preferensi Store terlihat dominan, dari sisi frekuensi aktivitas, online justru lebih sering digunakan.

```

spending = {
    'Online Spend': df['avg_online_spend'].mean(),
    'Store Spend': df['avg_store_spend'].mean()
}

plt.figure(figsize=(8,5))
sns.barplot(x=list(spending.keys()), y=list(spending.values()))
plt.title('Perbandingan Rata-rata Pengeluaran Online vs Offline')
plt.xlabel('Jenis Pengeluaran')
plt.ylabel('Rata-rata Pengeluaran')
plt.show()

```




Visualisasi di atas menunjukkan bahwa rata-rata pengeluaran pelanggan pada kanal online dan offline relatif seimbang, dengan nilai keduanya berada pada kisaran 74.000 sampai 75.000. Meskipun Store Spend sedikit lebih tinggi dibandingkan Online Spend, selisihnya sangat kecil sehingga dapat dikatakan tidak terdapat perbedaan signifikan dalam nilai pengeluaran rata-rata antar kanal.

Hal ini mengindikasikan bahwa pelanggan memiliki daya beli yang hampir sama, baik saat berbelanja secara online maupun langsung di toko fisik. Dengan kata lain, perbedaan kanal lebih memengaruhi frekuensi transaksi, bukan besarnya nominal pengeluaran rata-rata.

Composition

```
gender_counts = df['gender'].value_counts()

plt.figure(figsize=(7,7))
plt.pie(
    gender_counts,
    labels=gender_counts.index,
    autopct='%1.1f%%',
    startangle=90
)
plt.title('Distribusi Pelanggan Berdasarkan Gender')
plt.show()
```



Visualisasi di atas menunjukkan bahwa distribusi pelanggan berdasarkan gender sangat seimbang. Proporsi pelanggan Male sebesar 33,6%, Female 33,3%, dan Other 33,0%. Selisih antar kategori sangat kecil, sehingga dapat disimpulkan bahwa dataset memiliki persebaran gender yang hampir merata.


Keseimbangan ini mengindikasikan bahwa data pelanggan tidak terpusat pada satu kelompok gender tertentu, sehingga analisis lanjutan seperti perilaku belanja, frekuensi transaksi, maupun pengeluaran dapat dilakukan tanpa adanya bias dominasi dari satu kategori gender.

Selain itu, distribusi yang merata juga memberikan peluang untuk melakukan segmentasi perilaku pelanggan berdasarkan gender secara lebih objektif, misalnya untuk melihat apakah terdapat perbedaan preferensi kanal belanja, frekuensi pembelian, atau nominal pengeluaran antar gender.

```
city_counts = df['city_tier'].value_counts()

plt.figure(figsize=(7,7))
plt.pie(
    city_counts,
    labels=city_counts.index,
    autopct='%1.1f%%',
    startangle=90
)
plt.title('Distribusi Pelanggan Berdasarkan City Tier')
plt.show()
```


Distribusi Pelanggan Berdasarkan City Tier




Visualisasi di atas menunjukkan bahwa distribusi pelanggan berdasarkan city tier sangat merata. Proporsi pelanggan pada Tier 1 sebesar 33,8%, Tier 3 sebesar 33,5%, dan Tier 2 sebesar 32,7%. Perbedaan antar kategori sangat kecil, sehingga dapat disimpulkan bahwa dataset memiliki cakupan pelanggan yang seimbang di berbagai tingkat wilayah kota.

Keseimbangan ini menunjukkan bahwa data pelanggan tidak hanya terfokus pada kota besar saja, tetapi juga mencakup kota menengah dan berkembang. Dengan demikian, analisis perilaku belanja yang dilakukan nantinya akan lebih representatif untuk memahami pola konsumen di berbagai segmen wilayah.

Selain itu, persebaran yang merata ini memberikan peluang untuk mengevaluasi apakah terdapat perbedaan preferensi belanja, frekuensi transaksi, maupun rata-rata pengeluaran berdasarkan tingkat kota. Misalnya, pelanggan di Tier 1 mungkin memiliki kecenderungan lebih tinggi terhadap belanja online dibanding Tier 2 atau Tier 3.


▼ Distribusi

```
plt.figure(figsize=(10, 6))
sns.histplot(df['age'], bins=20, kde=True)
plt.title('Distribusi Umur ')
plt.xlabel('Keterangan X')
plt.ylabel('Frekuensi')
plt.show()
```




Visualisasi di atas menunjukkan bahwa distribusi usia pelanggan cukup merata dan cenderung simetris, terpusat di sekitar usia pertengahan (mean 48.73, median 49). Ini mengindikasikan bahwa data mencakup konsumen dari berbagai kelompok umur secara seimbang, mulai dari usia muda (min 18) hingga lebih tua (max 79). Keseimbangan ini penting untuk memastikan bahwa hasil analisis perilaku belanja dapat digeneralisasi ke segmen usia yang luas.

```
plt.figure(figsize=(10, 6))
sns.histplot(df['monthly_income'], bins=20, kde=True)
plt.title('Distribusi Pendapatan Bulanan ')
plt.xlabel('Keterangan X')
plt.ylabel('Frekuensi')
plt.show()
```




Histogram pendapatan bulanan menunjukkan distribusi yang relatif seimbang di seluruh rentang pendapatan (mean 131704, median 131916), tanpa puncak yang terlalu tajam atau kemiringan yang signifikan. Ini mengindikasikan bahwa dataset mencakup pelanggan dari berbagai tingkat ekonomi, mulai dari pendapatan rendah (min 15005) hingga tinggi (max 249989), memberikan gambaran komprehensif tentang daya beli konsumen.

```
plt.figure(figsize=(10, 6))
sns.histplot(df['daily_internet_hours'], bins=20, kde=True)
plt.title('Distribusi Aktivitas Internet Harian ')
plt.xlabel('Keterangan X')
plt.ylabel('Frekuensi')
plt.show()
```




Visualisasi ini menunjukkan distribusi jam penggunaan internet harian yang cenderung normal, dengan sebagian besar pelanggan menghabiskan sekitar 4 hingga 8 jam online setiap hari (mean 6.01, median 6.00). Distribusi ini mengindikasikan pola penggunaan internet yang moderat dan konsisten di antara populasi konsumen, menunjukkan tingkat keterlibatan digital yang stabil.

```
plt.figure(figsize=(10, 6))
sns.histplot(df['monthly_online_orders'], bins=20, kde=True)
plt.title('Distribusi frekuensi belanja online ')
plt.xlabel('Keterangan X')
plt.ylabel('Frekuensi')
plt.show()
```




Distribusi frekuensi belanja online bulanan menunjukkan penyebaran yang luas dan relatif simetris (mean 24.68, median 25). Ini mencerminkan variasi yang signifikan dalam kebiasaan belanja online antar pelanggan, mulai dari yang jarang bertransaksi (min 0) hingga sangat sering (max 49). Hal ini penting untuk dipertimbangkan dalam segmentasi pelanggan berdasarkan intensitas belanja digital mereka.

```
plt.figure(figsize=(10, 6))
sns.histplot(df['monthly_store_visits'], bins=20, kde=True)
plt.title('Distribusi frekuensi belanja offline ')
plt.xlabel('Keterangan X')
plt.ylabel('Frekuensi')
plt.show()
```




Histogram ini menunjukkan bahwa frekuensi kunjungan toko fisik bulanan cenderung miring ke kanan (right-skewed), dengan lebih banyak pelanggan yang jarang atau tidak pernah mengunjungi toko (min 0) dibandingkan yang sering. Meskipun ada beberapa pelanggan yang sering berkunjung (max 19), mayoritas cenderung melakukan kunjungan toko dalam frekuensi yang lebih rendah (mean 9.48, median 9). Ini mendukung temuan sebelumnya tentang dominasi preferensi belanja di toko secara umum, namun menunjukkan bahwa frekuensi kunjungan per pelanggan bisa bervariasi.

```
plt.figure(figsize=(10, 6))
sns.histplot(df['avg_online_spend'], bins=20, kde=True)
plt.title('Distribusi pengeluaran online ')
plt.xlabel('Keterangan X')
plt.ylabel('Frekuensi')
plt.show()
```



Visualisasi ini menunjukkan distribusi pengeluaran rata-rata online yang tersebar luas dan relatif seimbang (mean 74554.93, median 74859). Ini mengindikasikan bahwa ada pelanggan yang melakukan pengeluaran kecil (min 523) hingga besar (max 149996) secara online, mencerminkan keragaman daya beli dan kebiasaan belanja di kanal digital. Distribusi yang merata ini penting untuk memahami segmen pasar yang berbeda berdasarkan nilai transaksi online.

```
plt.figure(figsize=(10, 6))
sns.histplot(df['avg_store_spend'], bins=20, kde=True)
plt.title('Distribusi pengeluaran offline ')
plt.xlabel('Keterangan X')
plt.ylabel('Frekuensi')
plt.show()
```



Distribusi pengeluaran rata-rata di toko fisik juga menunjukkan pola yang luas dan relatif seimbang (mean 74619.50, median 75069), mirip dengan pengeluaran online. Ini menegaskan bahwa pelanggan memiliki variasi dalam jumlah yang mereka belanjakan di toko fisik, dari jumlah kecil hingga besar. Perbandingan antara pengeluaran online dan offline menunjukkan bahwa, meskipun frekuensi transaksinya berbeda, besarnya nominal pengeluaran rata-rata cenderung serupa di kedua kanal.

Relasi Hubungan

```
plt.figure(figsize=(8, 6))
sns.heatmap(data=df[['age',
    'monthly_income',
    'daily_internet_hours',
    'monthly_online_orders',
    'monthly_store_visits',
    'avg_online_spend',
    'avg_store_spend']].corr(),
    annot=True,
    cmap='viridis',
    fmt='.2f')
plt.title('Relasi Faktor Pengaruh Pembelian')
plt.show()
```

